

- 数学基础

- 线性代数：

- 谱定理（物理意义）：SVD实际就是将一个矩阵分解为两个旋转+一个缩放，对于对称矩阵，两个旋转矩阵是一样的，进一步拆开，就是特征值与特征向量（正交）的乘积；

$$A = U\Lambda U^T = \sum_{i=1}^n \lambda_i u_i u_i^T, \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$$

- 瑞利商：利用SVD物理意义理解——A分解后，旋转矩阵不会改变长度，只有缩放矩阵（这里是个对角矩阵，特征值），所以根据特征值大小，界定范围

Given a symmertric matrix $A \in S^n$,

Physical meaning of SVD!

$$\lambda_{\min}(A) \leq \frac{x^T A x}{x^T x} \leq \lambda_{\max}(A), \forall x \neq 0$$

$$\lambda_{\max}(A) = \max_{x: \|x\|_2=1} x^T A x$$

$$\lambda_{\min}(A) = \min_{x: \|x\|_2=1} x^T A x$$


- 概率论：

- 边缘概率（可以理解为全概率公式）：对联合概论的一个变量进行积分，即不考虑一个变量的影响；

Continuous:

$$p(x) = \int p(x, y) dy$$


$$p(y) = \int p(x, y) dx$$



Discrete:

$$p(x) = \sum_y p(x, y)$$

$$p(y) = \sum_x p(x, y)$$




- 条件概率：还是关心某个变量，例如y的，只是这时y值是确定的，即只考虑这个y = y1，不考虑其他y值，来看此时的联合概率分布；

$$P(x|Y = y^*) = \frac{p(x, Y = y^*)}{\int p(x, Y = y^*) dx} = \frac{p(x, Y = y^*)}{p(Y = y^*)}$$

- 变形后，得到贝叶斯公式！—— $p(x, y) = p(x|y)p(y) = p(y|x)p(x)$

○ 图论：


- 有向图：节点代表变量，边代表联系；如果没有联系， $p(x,y) = p(x)p(y)$ ，相互独立；
 - 马尔可夫假设：一个变量 x ，在给定父节点情况下，独立于它的非子节点！因为前驱节点的信息已经浓缩到父节点了，不需要再去参考前驱节点；



若子已知，则 x 独立于 Y

the joint distribution is $p(x, z) = p(z)p(x|z)$


- 无向图：MRF马尔可夫随机场/MN马尔可夫网络；同样的，给定所有父节点，则该变量与其他节点独立；



○ 优化方法：拉格朗日乘数法（多元微积分）：等高线的梯度于切线垂直啦！

- <https://blog.csdn.net/Queen0911/article/details/100611797>

$$\max f(x, y), \text{ s.t. : } g(x, y) = 0$$



- 可以看到，最值点处，等高线于条件约束相切！
- 在点p1、p2处，虽然满足约束，但是仍然可以向梯度，沿着红线约束方向前进，直到到达最值点，在红线上如何移动，都不是朝着梯度方向，不能增大了！
- 所以最值点一定满足：等高线梯度方向 于 条件约束梯度方向 在同一条线上（方向可不同），即：

引入拉格朗日乘数 $\nabla_{x,y} f = \lambda \nabla_{x,y} g$ 法：

$$\mathcal{L}(x, y, \lambda) = f(x, y) - \lambda g(x, y)$$

- $\nabla_{x,y,\lambda} \mathcal{L}(x, y, \lambda) = 0.$
- 整理求解得 到：可以看到即满足约束条件，又满足最值点的条件！

$$\nabla_{x,y,\lambda} \mathcal{L}(x, y, \lambda) = 0 \iff \begin{cases} \nabla_{x,y} f(x, y) = \lambda \nabla_{x,y} g(x, y) \\ g(x, y) = 0 \end{cases}$$

- 拉格朗日乘数法——专门用于求解带等式约束条件的优化问题！